

REDES NEURONALES

Tema 1: Fundamentos de las Redes Neuronales

1. Introducción

Las redes neuronales artificiales (RNA) son un conjunto de algoritmos inspirados en el funcionamiento del cerebro humano. Su objetivo es reconocer patrones y aprender relaciones complejas a partir de los datos. Forman la base del aprendizaje profundo (Deep Learning), una de las áreas más avanzadas de la inteligencia artificial.

Una red neuronal se compone de neuronas artificiales organizadas en capas. Cada neurona recibe una serie de entradas numéricas, realiza un procesamiento matemático y genera una salida. A través del aprendizaje, la red ajusta los pesos que determinan la importancia de cada entrada, minimizando el error entre la salida deseada y la obtenida.

En el ámbito de la informática y el análisis de datos, las redes neuronales permiten automatizar la toma de decisiones, reconocer imágenes, interpretar lenguaje, predecir comportamientos y optimizar procesos.

2. Neuronas artificiales: estructura y funcionamiento

La neurona artificial es la unidad básica de procesamiento de una red neuronal. Está inspirada en la neurona biológica, que recibe señales, las procesa y produce una salida. Matemáticamente, una neurona artificial transforma las entradas en una salida mediante una función de activación.

3. Funciones de activación

Las funciones de activación introducen no linealidad en la red, permitiendo que el modelo aprenda relaciones complejas.

Entre las más comunes se encuentran la función escalón, sigmoide, tangente hiperbólica (tanh), ReLU y Softmax. Cada una se elige según el tipo de problema (clasificación o regresión) y la capa de la red.

4. Arquitectura de una red neuronal

Una red neuronal se organiza en capas: capa de entrada, capas ocultas y capa de salida. Cada capa transforma los datos que recibe y transmite la información a la siguiente. Los pesos y sesgos determinan la influencia de las neuronas y se ajustan durante el entrenamiento.

5. Entrenamiento de una red neuronal

El entrenamiento consiste en ajustar los pesos y sesgos de la red para minimizar el error entre las predicciones y los valores reales. Incluye las fases de propagación hacia adelante, cálculo del error, retropropagación y actualización de pesos mediante optimización. Estos pasos se repiten durante varias épocas hasta que el modelo converge.

6. Función de pérdida y optimización

La función de pérdida mide la diferencia entre la predicción y la salida esperada. Su minimización se realiza mediante algoritmos de optimización como el descenso del gradiente, SGD o Adam. El objetivo es ajustar los pesos para reducir progresivamente el error.

7. Overfitting, regularización y normalización

El sobreajuste ocurre cuando el modelo aprende los datos de entrenamiento demasiado bien, perdiendo capacidad de generalización. Se previene mediante técnicas de regularización (L1, L2, dropout), normalización de datos y métodos como early stopping o data augmentation.

8. Evaluación del modelo

La evaluación permite medir la eficacia del modelo. Se utilizan métricas diferentes según el tipo de problema: accuracy, precision, recall, F1 y AUC en clasificación; MAE, MSE y R^2 en regresión. La validación cruzada mejora la fiabilidad de la evaluación.

9. Aplicaciones prácticas de las redes neuronales

Las redes neuronales tienen aplicaciones en visión artificial, procesamiento del lenguaje, análisis de datos, robótica y educación. Permiten el reconocimiento facial, diagnóstico médico, traducción automática, predicción de series temporales o personalización del aprendizaje. Su uso responsable y ético es clave para un desarrollo tecnológico sostenible.